NLP with Scala

Christoph Lüth and Martin Ring

28.09.2018

Agenda

- Introduction to NLP
- Introduction to Scala
- Tokenization and Splitting
- Word-level Analysis
- Named Entity Recognition
- Grammar Tree Analysis
- Dependency Analysis

NLP: Short History

- Early Resarch: Rule Based Parsing
- ▶ 1980s 1990s: Statistical Revolution
- ► Modern Days: Deep Learning and Statistics

Word Databases

▶ e.g. WordNet

S: (n) head, chief, top dog (a person who is in charge) "the head of the whole operation"

- <u>direct hyponym</u> / <u>full hyponym</u>
- direct hypernym | inherited hypernym | sister term
 - S: (n) leader (a person who rules or guides or inspires others)
 - S: (n) person, individual, someone, somebody, mortal, soul (a human being) "there was too much for one person to do"
 - S: (n) organism, being (a living thing that has (or can
 - develop) the ability to act or function independently)
 S: (n) living thing, animate thing (a living (or once living) entity)
 - S: (n) whole, unit (an assemblage of parts that is regarded as a single entity) "how big is that part compared to the whole?"; "the team is a unit"
 - S: (n) <u>object</u>, <u>physical object</u> (a tangible and visible entity; an entity that can cast a shadow) "it was full of rackets, balls and other objects"
 - S: (n) <u>physical entity</u> (an entity that has physical existence)
 - S: (n) entity (that which is perceived or known or inferred to have its own distinct existence (living or

NLP: Syntactical Concepts

- Sentence Splitting / Tokenization
- ► Lemmatization / Stemming
- Morphological Segmentation
- POS Tagging
- ▶ Parse Tree Generation

Splitting / Tokenization

- Word and sentence boundary recognition
- Often relatively simple:
 - ► Word Boundaries: [^\w,]+
 - ► Sentence Boundaries: [;.?!]+

Lemmatization / Stemming

- Stemming Reduce words to their stem:
 - lacktriangledown e.g. relational ightarrow relate, tanned ightarrow tan
 - Porter Stemming Algorithm:
 - ▶ $(m>0)EED \rightarrow EE$
 - $\blacktriangleright (*v*)ED \rightarrow ()$
 - $(*v*)ING \rightarrow ()$
- ▶ **Lemmatization** Reduce words into their uninflected form:
 - ightharpoonup e.g. [went, goes] ightharpoonup go
 - ightharpoonup e.g. People ightarrow Person
 - e.g. [are, is, been] \rightarrow s be

Morphological Segmentation

- In-word morpheme segmentation
- Importance depends on language
- English: irrelevant
- ► German: important

POS Tagging

The Seghorn AG is a successful company

DT Determiner


NNP Proper noun, singular

VBZ Verb, 3rd person singular present

JJ Adjective

NN Noun, singular or mass

Parse Trees




NLP: Semantic Concepts

- Named Entity Recognition
- Dependency Graph
- Coreference
- Sentiment Analysis


Named Entity Recogition



Dependency Graphs



Coreferences





- A scalable language
- ► Rein objektorientiert
- Funktional
- Basiert auf der JVM
- ► Seit 2004 http://www.scala-lang.org
- Seit 2011 kommerziell

Scala am Beispiel (01)

- Veränderliche Variablen (var)
- Unveränderliche Variablen (val)
- while-Schleifen
- Rekursion
- Typinferenz

Jetzt Sie: schreiben Sie eine Funktion, welche eine Zeichenkette n-mal wiederholt:

- Rekursiv
- ► Iterativ

Scala am Beispiel (02)

- Klassenparameter
- Klassenvorbedingungen
- private Werte und Methoden
- override nicht optional
- Overloading
- Operatoren
- Companion objects

Jetzt Sie: erweitern Sie die Klasse 'Rational'

- ▶ so dass ganze Zahlen ohne den Nenner 1 ausgegeben werden, und
- um Multiplikation und Division (* und /)
- um Gleichheit (Methode equals)

Scala am Beispiel (03)

- case classes:
 - Factory-Methode für Konstruktoren
 - Parameter als val
 - abgeleitete Implementierungen
 - pattern matching
- sealed verhindert Erweiterung
- Algebraische Datentypen

Jetzt Sie:

- Erweitern Sie die Klasse Expr um eine Funktion, welche einen Ausdruck schön ausgibt (Bonuspunkte für Berücksichtigung der Operatorpräzendenz)
- Ersetzen Sie das Argument von BinOp und UnOp durch einen geeigneten Aufzählungstyp


Nützliche Typen:

- Listen
- ► Tupel
- Maps und Mengen
- Arrays
- Options

Typsystem

- ▶ Das Typsystem behebt mehrere Probleme von Java:
 - ▶ Werte vs. Objekte
 - Scala vs. Java
 - ▶ NULL Referenzen
- Parametrische Polymorphie (Generics)
- Funktionen als Objekte
- Typvarianz (ask us later)

Typhierarchie



Traits

- Abstrakte Klassen ohne Oberklasse und Konstruktor
- Mehrfachvererbung von traits möglich
- ► Nützlich zur Strukturierung (Aspektorientierung)

Jetzt Sie: Definieren Sie eine Funktion, welche die Lösung des n-Damen-Problems ansprechend darstellt.

Mehr Scala:

- Nebenläufigkeit und reaktive Prorgammierung mit Aktoren (acca)
- ightharpoonup scala.js: Übersetzer Scala ightarrow Javascript
- ▶ sbt: simple build tool